正規表達式模組簡介

學習目標

- 正規表達式語法
- 使用 re 模組
- re 模組的 flag

正規表達式(Regular Expressions)

- 瞭解正規表達式(Regular Expressions)

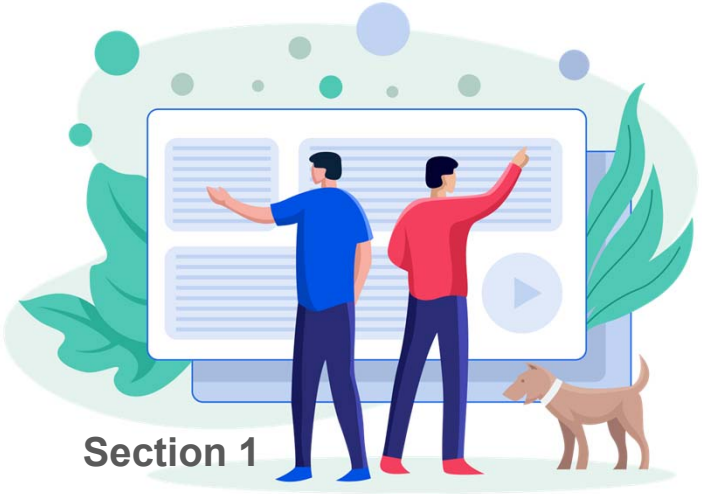

正規表達式

- 正規表達式(Regular expression, regex) 是一特殊順序的字元組成，用來搜尋符合條件的字串
- 使用一些特殊字元組成表達式(Expression)
- 在 UNIX 的領域廣泛使用
- Python 的 “re” 模組提供支援 Perl-like 語法的正規表達式
- 在編譯或使用正規表達式時如果有發生錯誤，會觸發 re.error 的例外(Exception)

使用正規表達式的步驟

- 使用 “import re” 匯入正規表達式模組
- 使用 re.compile() 方法建立 Regex 物件
  - 記得使用 raw string
- 將字串傳入Regex 物件的 search() 方法搜尋符合條件的字串
  - 該方法會傳回 Match 物件
  - 也可用另一個 match() 方法搜尋文字的開頭是否符合條件

```
import re
testpattern = re.compile(r'Hello')
result = testpattern.search('Hello World')
```

- 選擇性的，呼叫 Match 物件的 group() 方法取得實際符合條件的字串

特殊字元 -1

'.'	在預設模式，代表除了換行(\n)的任意一個字元
'^'	以匹配字串起始
'$'	以匹配字串結尾或是換行之前以匹配字串結尾結束
'*'	匹配前面的元素零次或多次，例如 ‘ab*’ 會匹配 ‘a’、‘ab’、‘abb’ 等
'+'	匹配前面的元素一次或多次，例如 ‘ab+’ 會匹配 ‘ab’ 、‘abb’、‘abbb’ 等
'?'	匹配前面的元素零或一次，例如 ‘ab?’ 會匹配 ‘a’ 或 ‘ab’
*?, +?, ??	將樣式(Pattern) 以非貪婪(non-greedy) 方式或是最少方式(minimal fashion) 進行匹配，取最少符合條件的字串。例如以 ‘<.*?>’ 匹配 ‘<a> b <c>’ 會得到 ‘<a>’

特殊字元 -2

{m}	匹配前面的元素精確地 m 次，例如 a{5} 會匹配 ‘aaaaa’
{m,n}	匹配前面的元件至少 m 次並且不超過 n 次，盡可能取最多匹配元件。例如 a{3,5} 會匹配 3 到 5 個 ‘a’。忽略 m 代表小於等於 n，忽略 n 代表大於等於 m
{m,n}?	匹配前面的元件至少 m 次並且不超過 n 次，盡可能取最少匹配元件。例如字串 ‘aaaaaa’，a{3,5} 會匹配到 ‘aaaaa’，而 a{3,5}? 則會匹配到 ‘aaa’
'\'	代表跳脫(escape) 某一特殊字元，允許你匹配 ‘*’、‘?’ 、‘.’ 等。或者表示一特殊序列(special sequence)

特殊字元 -3

'|'	選擇運算 A|B，A 與 B 可以是任意的 Res， 匹配 A 或 B
[ ]	●代表一個集合，用來匹配任何包含在括號內的單一字元 ●例如 [amk] 會匹配到 'a'、'm' 或 'k' ●'-' 代表字元範圍，例如 [a-z] 會匹配小寫英文字 ●假如括號內的第一個字為 '^'，代表反向(not)，所有不在集合內的字元會被匹配 ●在集合內的特殊字元會被視為一般字元
(...)	匹配括號內的任意正規表達式，也代表是一個群組(group)

模式 -1

abc	常值abc
(*expr*)	*expr*
expr1|*expr2*	*expr1*或*expr2*
prev?	零或一個*prev*
*prev**	零或多個*prev*，盡可能地多
*prev**?	零或多個*prev*，盡可能地少
prev+	一或多個*prev*，盡可能地多
prev+?	一或多個*prev*，盡可能地少

模式 -2

prev{m}	m個連續的*prev*
prev{m,n}	m至n個連續的*prev*，盡可能地多
prev{m,n}?	m至n個連續的*prev*，盡可能地少
[abc]	a或b或c，與 a|b|c 相同
[^abc]	非 (a或b或c)
prev(?=*next*)	*prev*，若接下來是*next*
prev(?!*next*)	*prev*，若接下不來是*next*
(?<=*prev*)*next*	*next*，若前面是*prev*
(?<!*prev*)*next*	*next*，若前面不是*prev*

正規表達式範例 -1

- '.' = {"a", "b", "c", ..., "A", "B", ... "@", ...}
- '^a' = {"a", "apple", "age", "amount" , "a happy day", ...}
- '^up' = {"up", "up and away", "upper", "upon", ...}
- 'ear$' = {"ear", "clear", "top gear", ...}
- 'b*' = {"", "b", "bb", "bbb", ...}
- 'ab*' = {"a", "ab", "abb", "abbb", ...}
- '(ab)*' = {"", "ab", "abab", "ababab", ...}
- '(ab)+' = {"ab", "abab", "ababab", ...}
- '(ab)?' = {"", "ab"}

正規表達式範例 -2

- 'b{4}' = {"bbbb"}
- 'ab{4}' = {"abbbb"}
- '(ab){4}' = {"abababab"}
- 'b{,4}' = {"", "b", "bb", "bbb", "bbbb"}
- 'ab{4,}' = {"abbbb", "abbbbb", "abbbbbb", ...}
- '[abc]' = {"a", "b", "c"}
- '[a-zA-Z]' = {"a", "A", "b", "B", ..., "z", "Z"}
- '[0-9]' = {"0", "1", "2", ..., "9"}
- '[^aeiou]' = {"b", "c", "d", "f", "g", ...}
- '[a\-z]' = {"a", "-", "z"}

編譯標誌(Compilation Flags)

re.A re.ASCII	讓 \w, \W, \b, \B, \d, \D, \s 和 \S 只匹配ASCII，而不是Unicode
re.I re.IGNORECASE	忽略大小寫匹配，大小寫視為相同
re.L re.LOCALE	由目前語言來決定 \w, \W, \b, \B 和大小寫的匹配
re.M re.MULTILINE	多列匹配，影響到 '^' 與 '$'
re.S re.DOTALL	讓 '.' 匹配任何字元，包括換行字元
re.X re.VERBOSE	允許编寫更具可讀性的正規表達式，可以分段與加註解

常用方法(Methods) -1

- re.compile(pattern, flags=0)
  - 將正規表達式的樣式編譯成物件(Regex object)，可以透過該物件的方法來匹配符合條件的資料，例如 match()、search()、findall() 等
  - prog = re.compile(pattern)
    result = prog.match(string)
    相當於
    result = re.match(pattern, string)
  - 如果需要多次使用相同的正規表達式，使用 re.compile() 將其事先編譯以便重複使用，可以提高效能

常用方法(Methods) -2

- pattern.search(string[, pos[, endpos]])
  - 掃描整個 string，搜尋第一個匹配的位置，傳回相對應的物件。如果没有符合條件，就傳回 None。可以接收 pos 和 endpos 參數，限制搜索範圍
- pattern.match(string[, pos[, endpos]])
  - 掃描 string 開頭位置，如果符合匹配條件，就傳回相對應的物件，否則就傳回 None。pos 和 endpos 參數，可以限制搜索範圍
- pattern.fullmatch(string[, pos[, endpos]])
  - 如果整個 string 符合匹配條件，就傳回相對應的物件，否則就傳回 None。 pos 和 endpos 參數，可以限制搜索範圍

正規表達式(Demo)

- 如何使用正規表達式(Regular Expressions)

本章重點精華回顧

- 正規表達式(Regular Expressions)
  - 語法簡介
  - 模組使用

Lab:正規表達式(Regular Expressions)使用

- Lab01: 使用正規表達式(Regular Expressions)

Lab01: 使用正規表達式(Regular Expressions) -1

1. 啟動Python IDLE環境，做以下練習
2. 使用 “File/Open...” 開啟 “regex.py” 程式，了解正規表達式的用法
3. 開啟命令列(cmd)，切換到labs相關目錄，做以下測試
4. 顯示有包含 ‘the’ 的文字列
   python regex.py regex_data.txt
5. 將pat=r'the' 改為pat=r'[Tt]he'，顯示有包含 ‘the’ 或 ‘The’ 的文字列
   python regex.py regex_data.txt
6. 將pat=r'[Tt]he' 改為pat=r'\d'，顯示有包含數字的文字列
   python regex.py regex_data.txt

Lab01: 使用正規表達式(Regular Expressions) -2

7. 將pat=r'\d' 改為pat=r'\d{3}'，顯示有包含3位數字的文字列
   python regex.py regex_data.txt
8. 將pat=r'\d{3}' 改為pat=r'^[A-Z]'，顯示有大寫字元開頭的文字
   python regex.py regex_data.txt
9. 將pat=r'^[A-Z]' 改為pat=r'^[^A-Z]'，顯示非大寫字元開頭的文字列
   python regex.py regex_data.txt
10. 將pat=r'^[^A-Z]' 改為pat=r'b.t'，顯示b與t之間有一個任意字元的文字列
    python regex.py regex_data.txt
11. 將pat=r'b.t' 改為pat=r'\.$'，顯示句點結尾的文字列
    python regex.py regex_data.txt
12. 關閉regex.py程式視窗